

ОТЧЁТ ПО ЭТАПУ №4

Создание прототипа ИС и получение первой точности распознавания

Автор: Андреев Вячеслав

Направление: AI/ML/TTS

Университет Искусственного Интеллекта, 2026

1. ТЕМА И ОПИСАНИЕ ЗАДАЧИ

Тема: «Интеллектуальная система озвучивания аудиокниг с алгоритмическим улучшением просодии»

Описание задачи:

Разработать прототип пайплайна преобразования художественных текстов в речь, в котором качество синтеза повышается за счёт алгоритмической предобработки текста (NLP-модуль расстановки просодических пауз) без переобучения базовой TTS-модели.

Цель текущего этапа:

- Создать работающий прототип ядра системы (NLP + TTS)
- Получить первые метрики качества синтеза (MOS-оценка)
- Сравнить базовый синтез (Baseline) с улучшенным (Enhanced)

2. БАЗА ДАННЫХ

В рамках проекта сбор обучающей базы не требуется, так как используется предобученная модель Silero TTS v5, обученная на открытых русскоязычных датасетах (RUSLAN, Common Voice RU).

Для валидации прототипа сформирована тестовая выборка из художественных текстов, перешедших в общественное достояние (авторы умерли до 1954 г.).

Объём выборки: 10 отрывков по 200-500 слов каждый.

Источники: Lib.ru, Wikisource (лицензия Public Domain).

3. ПАРАМЕТРИЗАЦИЯ ДАННЫХ

Все ключевые параметры подобраны эмпирически на предыдущих этапах и зафиксированы в отчётах папки experiments/:

Параметр	Значение	Обоснование
----------	----------	-------------

sample_rate	16000 Гц	Эксперимент с 4 вариантами (8k/16k/24k/48k)
max_chars (чанк)	100 симв.	Учёт накладных расходов тегов пауз (+27%)

PAUSE_SHORT	0.3 сек	Запятая
PAUSE_MEDIUM	0.6 сек	Точка с запятой, тире
PAUSE_LONG	1.0 сек	Конец предложения
PAUSE_XLONG	1.5 сек	Абзац, многоточие

Формат аудио	float32	Требуется для soundfile
Диапазон	[-1, 1]	Стандарт WAV

Метрика качества: MOS (Mean Opinion Score) — субъективная оценка по шкале 1-5 (естественность, уместность пауз, общая приятность восприятия).

4. АРХИТЕКТУРА СИСТЕМЫ (ПРОТОТИП)

Прототип представляет собой композицию из трёх модулей, работающих последовательно:

Входной текст
(художественный)



МОДУЛЬ 1: NLP-ПРЕПРОЦЕССОР
(text_processor.py)

- Нормализация текста (пробелы, многоточие)
- Расстановка тегов пауз [spk=0.3/0.6/1.0/1.5]
- Морфологический анализ (py morphology3)
- Интеллектуальное чанкование (≤100 симв.)



МОДУЛЬ 2: TTS-ДВИЖОК
(Silero TTS v5, torch.hub)

- Синтез речи для каждого чанка
- Спикер: aidar_v2
- Sample rate: 16000 Гц



МОДУЛЬ 3: ПОСТ-ОБРАБОТКА
(tts_pipeline.py)

- Конкатенация чанков
- Нормализация амплитуды
- Сохранение в WAV (float32)



Выходной WAV
(озвученный
текст)

Технологический стек:

- Python 3.12
- PyTorch 2.11.0+cpu
- Silero TTS v5 (snakers4/silero-models)
- pymorphy3 (морфологический анализ)
- soundfile, numpy (работа с аудио)

5. ГРАФИЧЕСКОЕ ПОДТВЕРЖДЕНИЕ (ПЕРВЫЕ МЕТРИКИ КАЧЕСТВА)

Проведено A/B-тестирование на выборке из 10 отрывков
(5 поэзия + 5 проза). Каждая озвучка оценена по шкале MOS (1-5).

Жанр	Baseline MOS (без NLP)	Enhanced MOS (с паузами)	Δ Прирост
Поэзия	2.8	4.4	+1.6
Проза	3.3	4.0	+0.7
СРЕДНЕЕ	3.05	4.2	+1.15

Интерпретация результатов:

- Алгоритмическая предобработка улучшает MOS в среднем на 1.15 балла
- Максимальный эффект наблюдается на поэзии (+1.6) — это связано с совпадением пунктуационных и метрических пауз
- На прозе прирост меньше (+0.7), но всё равно значимый

6. РАБОЧИЙ НОУТБУК

Прототип реализован в Jupyter Notebook и состоит из следующих модулей:

1. Установка зависимостей (torch, soundfile, pymorphy3)
2. Загрузка модели Silero TTS v5
3. Класс TextPreprocessor (NLP-предобработка)
4. Функции синтеза: `synthesize_baseline()` и `synthesize_enhanced()`
5. A/B-тест на тестовом тексте
6. Сохранение результатов в WAV

Код прототипа: <https://github.com/stragas/audiobook-tts-diploma>

Ключевые файлы:

- `src/text_processor.py` — NLP-модуль
 - `src/tts_pipeline.py` — интеграционный пайплайн
 - `experiments/` — отчёты по экспериментам
-

7. ВЫВОДЫ

По итогам Этапа №4:

1. ☒ Создан работающий прототип пайплайна NLP → TTS → Audio
2. ☒ Получены первые метрики качества (MOS-оценка)
3. ☒ Подтверждена гипотеза: алгоритмическая предобработка улучшает качество синтеза на 1.15 балла MOS в среднем
4. ☒ Выявлена особенность: максимальный эффект на поэзии (+1.6)
5. ☒ Все параметры экспериментально обоснованы и задокументированы

Научный вклад этапа:

Показано, что улучшение просодии возможно без переобучения акустической модели — за счёт интеллектуальной предобработки текста на основе синтаксического анализа.

8. ПЛАН ДАЛЬНЕЙШЕЙ РАБОТЫ

Этап №5: Создание финальной версии HC

- Разработка веб-интерфейса на Gradio
- Реализация A/B-теста в интерфейсе (сравнение Baseline/Enhanced)
- Публикация публичной ссылки для демонстрации

Перспективные направления развития (после защиты):

- Режим «Поэзия» с увеличенными паузами
 - Автоматическое распределение ролей в диалогах
 - Интеграция фоновых звуков (SFX) по ключевым словам
-

ВОПРОС: 5 этап повторять сдачу не нужно? зачете или другой вариант? Уточните, пожалуйста.